校务 / 赛事通知可信问答助手

技术文档 · 第九届传智杯 AI 创新应用挑战赛（个人赛 / B 组）

从「能回答」到「可被审计的判断」

作品版本：v1.0（2026-11-09）

技术栈：Python 3.13 标准库核心 + FastAPI 薄封装（可选）

核心约束：运行时零第三方依赖、零 API key、零联网

文档页数：见目录，全文不超过 30 页（官方要求）

摘要

本项目不做一个「更流畅的通知问答机器人」，而做一个**对多源通知口径作出可证伪裁决、且全过程可复现**的系统。它面向的真实痛点是：同一赛事的通知分散在官网、高校转发、个人中心、提交表单和群内声明等多个渠道，写法不一致、会出补充通知、关键信息藏在会过期的附件里；学生据此判断「到底哪天截止」「该信哪个链接」时，一旦采信被排除的口径就可能失去参赛资格。

系统的技术选择因此与常见 RAG 相反：**默认不生成答案**，而是把通知拆成带原文逐字校验的原子断言，用规则层做检索、裁决、拒答与引用，把 LLM 严格限制在离线构建期与对照组。这样换来的是可核查性、可复现性与零依赖，而不是文采。

> **本文三主题**：第 4 章「意图控制策略」、第 5 章「架构设计」、第 8 章「可复现性论证」，均为官方提交要求点名的重点。

目录

1. 真实痛点与需求证据
2. 作品定位与创新点
3. 数据资产与语料构建

4. 意图控制策略
5. 架构设计
6. 功能与界面
7. 评测体系：基准集、消融与对照实验
8. 可复现性论证
9. 局限性与诚实边界
10. 评审维度映射与交付物

1. 真实痛点与需求证据

项目的痛点不是自述的。2026-11-09 共核实 12 项一手资料，下列为最关键的四类证据；完整索引与逐字摘录见 `evidence/research/README.md`，可信度分级与剔除清单见 `OPTIMIZATION.md`。

1.1 校方正式承认信息分散（A+）

池州学院校长信箱 2026-10-10 收到学生来信：「大量由二级学院、实验室或社团牵头的赛事信息处于『隐形』状态，导致普通学生错失参赛机会，形成了『信息垄断』」，建议「建立年度竞赛总览方案并挂网公示，明确牵头部门/学院、具体联系人及时间节点」。教务处 2026-10-13 正式回复：「针对赛事信息分散问题，教务处将进一步统筹…集中公示赛事主办单位、联系人、时间安排等信息，拓宽赛事信息获取渠道」，并承诺「统一校内认定口径」。

来源：https://www.czu.edu.cn/xjxq.jsp?urltype=leadermail.LeaderMailContentUrl&wbtreeid=1069&leadermailid=cghp ｜时效 2026-10｜可信度 A+（校方官网正式往来）

1.2 官方校园媒体给出可产品化的字段原型（A-）

中国大学生在线 2026-10-07《读懂学校通知是大学生的必修课》指出：通知分散于「班级群 / 学校·学院公众号 / 教务处网站 / 学生手册」；读通知要「圈出关键信息，时间、地点、对象、要求、截止时间」；「真正的干货是在附件里…以免文件过期，无法查看」；「凡是带截止时间的，马上写在手机日历或带有提前提醒的 APP 里」；「截止时间过了，你没注意，机会就错过了」。

本项目据此把「五要素」做成结构化卡片，并提供本地生成的 `.ics` 日历提醒；对附件与链接只做保守状态标记，不猜测有效期。

来源：https://xyh.univs.cn/a/xyh_xyh_zhrj/261007/2057146.shtml ｜时效 2026-10-07｜可信度 A-（官方平台原创经验文章，非调查数据，不作为统计比例）

1.3 条款级部分覆盖是真实语义，而非设想（A）

多所高校的「补充/调整通知」使用显式效力措辞：

- 宁波大学 2026-11-07：「参赛对象、作品类别、参赛资格及其他未尽事项，按学院原竞赛通知及学校相关要求执行；**申报方式和时间安排以本补充通知为准**」。
- 温州大学 2026-10-22：「**初赛、复赛时间保持不变**…决赛竞赛形式、参赛人员配置、题型设置、奖项设置…均不作调整，按照原通知执行」。
- 云南大学：「参赛作品提交截止时间调整为…；**参赛报名截止时间仍按原通知执行**」，并明确「后续评审、答辩及作品提交等相关通知将在群内发布」。

这说明普通 RAG 的「整份文档检索 + 并列展示」不足以表达真实效力关系：覆盖是**条款级**的，必须同时输出「哪些条款被覆盖」与「哪些明确沿用」。

1.4 信息过载与错过焦虑有学术实证（A，质性）

SEARCH 17(2), 2025 期刊论文（辽宁高校学生微信日记研究）指出：「Information overload emerged as a core trigger of WeChat fatigue, particularly in high-density group communication environments such as university classes, internship groups, and administrative announcements」；`@all` 穿透免打扰造成失控感；受访者日记原句「Some of the important

information is topped off!」；任务信息持续流入造成 hyper-responsiveness 与「fearing they might miss important instructions」的慢性焦虑。

> 适用边界：质性日记研究，样本为辽宁高校学生，**不外推为全国比例**；仅用于解释「为何要降低阅读负担、为何拒答要给出下一步指引」。

1.5 项目自身的一手证据（A+）

备赛过程中，2026-11-09 登录态抓取的官网原文即出现多重口径：省赛提交截止 11-18 15:00（大赛通知页与提交表单双重确认）；参赛流程页给出 kdocs 直链，而赛道详情页写「缴费后个人中心查看，不再单独提供外部链接」；国赛二等奖同页写 20% 与 25%、三等奖写 35% 与 30%；官网报名期写 7-29 起，高校转发通知写 9-1 起。**用户本人就是受影响用户。**

2. 作品定位与创新点

维度	普通 RAG	本作品
输出形态	生成一段流畅答案	裁决书：结论句 + 原文片段 + 引用 + 口径差异 + 渠道对照 + 五要素卡片
检索单位	文本块	文本块 + **原子断言**（141 条，逐字回查原文）
冲突处理	并列列出 / 交给模型总结	显式规则裁决 + 条款级覆盖 + 不擅自合并
无依据时	可能编造	拒答 + **证据缺口说明**（为什么查不到、去哪核对）
过程证据	无	基准集 + 消融矩阵 + 细粒度 Git + 9 条 Prompt 链
运行时依赖	向量库 / LLM / key	标准库零依赖；LLM 仅离线构建与对照组

五个核心创新点

1. **断言级时态台账**：每条通知拆成带 `effective_from` / `channel` / `supersedes` / `scope` 的原子断言，只信任逐字回查过原文的条目。
2. **口径裁决而非冲突提示**：按权威度 → 发布时点 → 官方原文 → 二手整理稿的显式规则排序，输出「排序最高的来源记载为…」，并声明「其余口径未作合并裁定」。
3. **可证伪基准集**：24 题人工标注，含负样本（同日异写）、应拒答题、附注多跳题；标准答案不由 LLM 生成，判卷只用确定性规则。
4. **反事实消融矩阵**：10 组开关，量化每个设计的贡献（见第 7 章）。
5. **裁决书式输出**：可审阅、可下载（`.ics`）、可分享（`#q=`），而非聊天气泡。

3. 数据资产与语料构建

资产	规模	构建方式	校验
`data/docs/official-01..06.md`	6 份官方原文	2026-11-09 登录态抓取（官网通知页 / 赛道详情 / 个人中心参赛流程 / WPS 表单）	原文逐字存档于 `evidence/official/`，本人联系方式已脱敏
`data/docs/demo-01..04.md`	4 份 DEMO	交接文档整理稿，标注「非官方原文」	authority=2，作为反例样本演示「二手稿不得凌驾官方」
`data/claims.json`	141 条断言	`deepseek-flash` 离线抽取，仅构建期调用	`evidence_span` 必须是原文连续子串，**141/141 通过**；2 条未通过项保留在 v1 记录并公开更正
`data/benchmark-v1.json`	24 题 / 7 类	人工标注：必含值、禁用值、gold 文档、冲突文档、拒答标记、原文回指	标准答案不由 LLM 生成；同一基准集复跑，不刷题
`data/channels.json`	6 级渠道 / 10 份文档 / 4 个跨渠道案例	按官网与高校一手页面人工标注	每条可回溯到公开 URL
`data/coverage.json`	4 个条款级覆盖样本	只采用通知原文显式效力措辞	不推断、不把整份旧通知判为作废
`data/campus/`	3 份高校摘录	西交大 / 韩山师范 / 三校补充通知	电话、邮箱、群号脱敏；**不进入检索语料**，仅作证据

> **隐私边界**：公开仓库不含真实手机号、邮箱、API key；`evidence/official/raw-process.txt` 已脱敏；`git log -S"sk-"` 复核为空。

4. 意图控制策略（官方点名主题一）

4.1 五条硬约束

`SYSTEM_PROMPT` 明确：只能依据提供片段作答、禁止编造日期/比例/金额/编号；每个结论标注来源编号；口径不一致须并列且禁止擅自选定；资料不足只输出「知识库中没有可靠依据」；转述用「据资料记载」，不把整理稿写成官方定论。

关键在于：**这些约束不依赖模型自觉。**默认运行时 `ALLOW_ONLINE_LLM` 硬门禁关闭，答案由规则层产生；LLM 只在离线构建期抽取断言、以及作为被测的「纯生成基线」出现。

4.2 显式规则表（可关闭、可消融）

规则	触发	行为	消融开关
权威度 / 时效加权	每次检索	score × f(authority) × f(recency)	`no_authority` / `no_recency`
同义扩展	「入口」vs「提交链接」	7 组领域同义词，权重 0.45	`no_expansion`
日期归一化	口径差异检测	2026-11-18 / 2026年11月18日 / 2026-11-18 15:00:00 归一键	`no_date_norm`
语义级拒答	主题未被覆盖 / 问金额但无金额证据	拒答 + 证据缺口说明	`no_semantic_abstain`
断言补充召回	数字、比例、页数类查询	从 141 条断言补原文片段，用 [补充N] 标记	`no_claims`
裁决结论句	正常作答	照录最高排序来源原句，声明不合并口径	`no_verdict`
附加证据区块	渠道/条款/后果/缺口触发词	渠道对照、条款级覆盖、证据缺口、决策后果与时效	`no_enrich`

4.3 拒答边界的两次修正（真实过程）

初版只在「检索结果为空」时拒答，导致问「省赛答辩在哪天」时把「报名截止」片段硬答。修复采用两条通用规则（断言分 < 1.0 且 top1 < 12 且首位片段覆盖率 < 0.30；问金额但证据无金额单位）。随后最终验证又发现自引入回归「选错组别会怎样」被误拒，补入覆盖率保护。阈值来自 24 题分数分布，属**可复现的经验阈值**，并全部做成可关闭开关。

5. 架构设计（官方点名主题二）

5.1 分层

1. **数据层**：`loader.py` 读 frontmatter 文档；`chunker.py` 做段落切分，并把小节标题并入正文（避免 8 字空壳块在 BM25 里挤掉含答案解析）；`claims.py` 建断言索引。
2. **检索层**：`retriever.py` 中文 bi-gram + BM25 + 权威度/时效先验 + 可关闭同义扩展。
3. **裁决层**：`answer.py` 去重、语义拒答、口径差异检测、裁决句、原文片段与补充片段编号分离；`context.py` 提供渠道对照、条款级覆盖、证据缺口、决策后果与时效状态。
4. **工件层**：`card.py` 生成五要素卡片与 RFC 5545 `.ics`。
5. **服务层**：`server.py`（标准库，零依赖）与 `main.py`（FastAPI，可选）提供同一组接口 `/health` `/sources` `/ask` `/`，行为一致。
6. **界面层**：`web/index.html` 单文件、无 CDN、无框架、深色主题、响应式。

5.2 一个关键设计：正文编号与 citation 严格一致

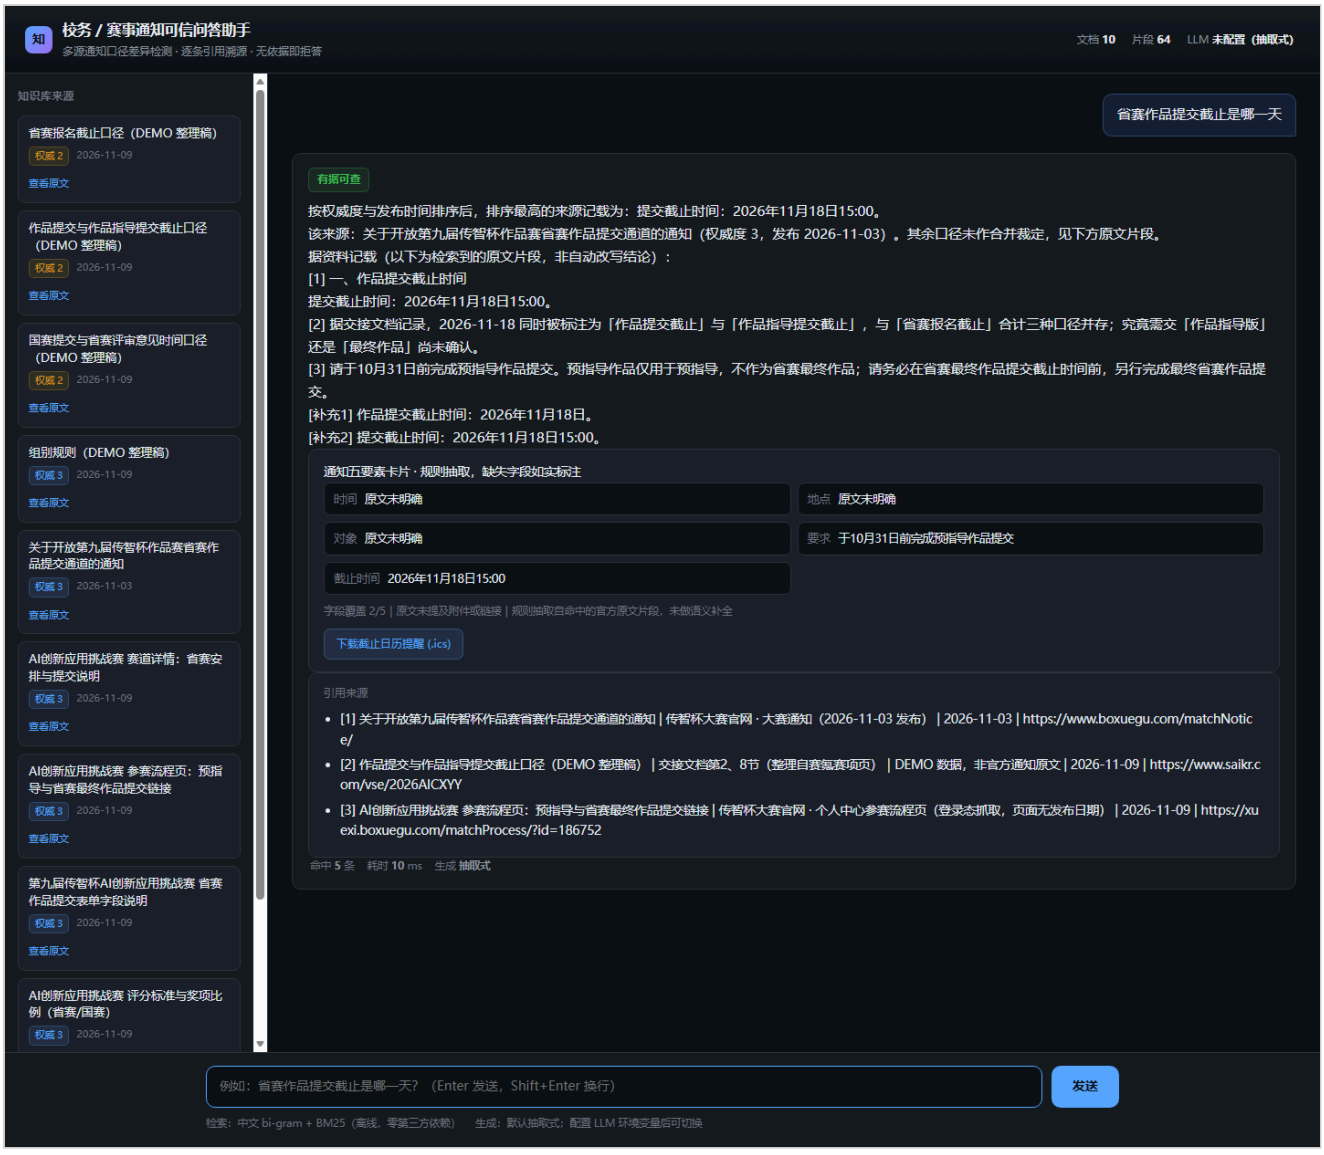
补充断言片段若占用 `[2][3]` 编号而 citation 列表并无对应项，等于伪造溯源。系统因此把补充片段固定标为 `[补充1]/[补充2]`，正文 `[1][2][3]` 只对应 `citations` 中的条目，并有专门回归测试锁死。

5.3 双服务与依赖边界

官方要求 10 分钟极速复现。核心全部使用 Python 标准库，裸 Python 即可运行 `python -m app.server --port 8000`；FastAPI 版在联网装齐依赖后可用，二者接口语义一致。本会话中 `pip` 的 simple index 请求被代理拦截（403），改用 PyPI JSON API 直连下 wheel + `--no-index --find-links` 离线装齐并完成全端点实测；`.wheels/` 已加入 `.gitignore`，不进仓库。

6. 功能与界面

界面包含：知识库来源侧栏（标题 / 权威度 / 发布时间 / 原文链接）、问题输入与示例快捷按钮、裁决结论句、原文片段与补充片段、引用来源、口径差异黄色警示、**通知五要素卡片**（时间 / 地点 / 对象 / 要求 / 截止时间，缺失字段如实标「原文未明确」）、**下载 .ics 日历提醒**、拒答状态与耗时统计、可分享的 `#q=` 问题链接。



截图存档：`evidence/screenshots/04-card-and-verdict.png`。另有 01 空状态、02 口径差异、03 修复后答案三张。

6.1 证据缺口与渠道对照（真实输出示例）

> 问「省赛答辩安排在哪一天？」→「知识库中没有可靠依据（检索片段与断言资产均未覆盖问题的核心对象）…【证据缺口】公开网页未收录该事项；多份高校通知明示『后续通知将在群内发布』，请核对本校报名群 / 教务处 / 牵头部门联系人，不要以非官方转述为准。」

系统只引用官方原文的**渠道声明**，不抓取群消息、不虚构联系人、不编造群内内容。

7. 评测体系：基准集、消融与对照实验

7.1 指标口径均有出处

指标	来源
归因可核查率（FS=1.0 / PS=0.5 / NS=0 加权）	TREC 2024 RAG 支持度评测，arXiv:2504.15205（SIGIR 2025）
引用完整性	ALCE，arXiv:2305.14627（EMNLP 2023）
冲突感知 / 逐文档标注	ConflictScore，arXiv:2606.26437（2026-06）简化版
hallucination / noise sensitivity 命名	RAGChecker，arXiv:2408.08067（NeurIPS 2024 D&B）
冲突类型只做 inter-context	Knowledge Conflicts for LLMs: A Survey，arXiv:2403.08319

> **LLM 不作裁判**：TREC SIGIR 2025 报告人类与 GPT-4o 三级判断完全一致率仅 56%→72%，因此基准集人工标注、判卷只用确定性规则；纯生成 LLM 仅作被测对象。

7.2 主对照（固定基线产物，可复跑）

指标	修复前	修复后	纯生成基线
结论正确率	45.8%	**66.7%**	66.7%
应拒尽拒率	0.0%	**100.0%**	100.0%
冲突感知率	12.5%	**37.5%**	37.5%
错误口径采信率	16.7%	12.5%	**8.3%**
归因可核查率	97.7%	**93.2%**	79.5%

检索层：`recall@3 = 6/8 (75%)`、`recall@5 = 8/8 (100%)`；单测 **35 个全过。**

7.3 消融矩阵（Δ 相对 full）

关闭项	结论正确率	Δ	解读
full	66.7%	—	基线配置
no_claims	45.8%	**-20.8pp**	断言补充召回贡献最大
no_semantic_abstain	54.2%	**-12.5pp**	语义拒答有效
no_date_norm	66.7%	0pp	对正确率无影响，但全题冲突总数 27→30（归一化减少 3 条误报）
no_authority	66.7%	0pp	对正确率无影响，冲突总数 27→32（抑制 5 条噪声）
no_expansion / no_abstain / no_verdict / no_enrich	66.7%	0pp	**如实记录「本基准集上无可观测影响」**，不硬造差异

完整表格见 `evidence/eval-report.md`；实验产物 `evidence/baseline/run-001.json`、`evidence/ablation/table.json`。

7.4 一次公开更正

首版判卷把 2 条落在 frontmatter 元数据里的断言误报为「模型编造」，实为提示词未禁抽元数据 + 校验器只比对正文。v1 记录原样保留（`evidence/claims-build-v1.md`），修正后重跑 141/141。系统不只校验 LLM 输出，也校验自己的判定器。

8. 可复现性论证（官方点名主题三）

8.1 10 分钟复现路径

1. 克隆 Public 仓库，使用 Python 3.13（无需虚拟环境）。
2. `python -m unittest discover -s tests -q` → 35 个测试通过。
3. `python -m app.cli --eval` → `recall@3 6/8`、`recall@5 8/8`。
4. `python -m app.server --port 8000` → 浏览器打开 `http://127.0.0.1:8000/`。
5. 全程**不需要 API key、不需要联网、不需要安装第三方包**；`data/claims.json` 与基准集均已固化入库。

可选：`.env.example` 提供环境变量模板；`ALLOW_ONLINE_LLM` 默认关闭，即便传入 `--llm` 也不会发出云端请求（实测 `LLM降级=True`）。FastAPI 版需 `requirements.txt`，装好后 `uvicorn app.main:app`，接口与标准库版一致。

8.2 过程可复现的三重证据

- **细粒度 Git**：每次提交对应一个功能模块或一次真实修复，禁止一次性全量提交；`evidence/devlog.md` 逐条回填 commit 与验证结果。
- **Prompt 链**：9 条完整链路（P-001~P-009），其中 P-002、P-005、P-006、P-007、P-008 含真实出错后的修 Bug 引导；不虚构、不事后补写。
- **实验可重跑**：`tools/run_eval_v1.py` 支持 `EVAL_REUSE_BASELINE=1` 固定基线产物；`tools/score_eval.py` 用确定性规则判卷，报告可复现。

8.3 原创性自证

作品从零构建，核心检索、切分、裁决、拒答、评测、界面均为本项目编写；未直接使用任何已有开源项目包装参赛。唯一外部运行资产是已固化并逐字校验的断言数据与公开通知原文；第三方框架仅 FastAPI 作为可选薄封装。依赖清单、环境变量模板、10 分钟指南齐备。

9. 局限性与诚实边界

- **不宣称超越生成基线**：修复后结论正确率与纯生成基线持平（66.7%），错误口径采信率 12.5% 仍高于基线 8.3%；生成基线在综合表述上仍有优势。
- 判卷是确定性关键词匹配，语义等价但措辞不同的表述可能被误判，数值是**下界**；结论只适用这 24 题与当前 10 份语料，不代表泛化能力或评审分数。
- 语义拒答阈值（1.0 / 12 / 0.30）来自该基准集分数分布，换语料需重新标定；已做成可关闭开关。
- 检索是词法基线，不是语义向量模型；URL 类长 token 的召回仍弱，未引入向量库或 rerank。
- 口径差异检测是规则基线（强时间词 + 日期），不识别无日期的语义级矛盾；措辞始终为「口径差异」而非「事实矛盾」。
- S1/S2 的宏观统计、S11 的质性结论均标注了样本与适用条件，**未外推为本作品用户比例。**
- 未接入群消息、未猜测附件有效期、未虚构联系人或金额；所有「原文未明确」字段如实留白。

10. 评审维度映射与交付物

官方维度	权重	本作品落点
过程可复现性与演进链路	25%	细粒度 Git、9 条 Prompt 链、基准集 + 消融 + 评测报告、10 分钟复现
解题有效性与实用价值	25%	12 项一手需求证据、真实 11-18 口径事件、裁决书 + 后果 + 时效状态
方法创新性与意图控制	20%	断言台账、条款级覆盖、渠道效力层级、显式规则表与拒答边界、消融证明
工程质量与架构设计	15%	分层解耦、零依赖核心、双服务一致、编号与 citation 一致性测试
用户体验与产品精细度	15%	裁决书界面、五要素卡片、ICS 下载、拒答态与耗时、移动端响应式

提交物清单

- 代码仓库（GitHub/Gitee Public，含细粒度提交历史与 README）
- 完整作品文件网盘链接（源码 + 文档 + 证据，含提取码）
- 作品介绍文档（7 项要求，单文件 ≤100MB）
- 演示视频链接（5–8 分钟 MP4 1080p，含 ≥2 分钟 AI 协同复现，B 站/抖音公开链接）
- 技术文档（本文，PDF ≤30 页）

文档生成：2026-11-09 由 HTML 经无头浏览器打印为 PDF；页数由 pdfplumber 校验。所有数字均可在 `evidence/` 对应产物中复验。